



گزارش تکلیف کامپیوتری شماره یک

پیاده‌سازی و آزمون طبقه‌بند Bayes Minimum Error (BME) روی مجموعه‌های داده Iris, Normal و Liquid



علیرضا مهدی‌زاده 40416814

دانشجوی کارشناسی ارشد هوش مصنوعی دانشگاه صنعتی اصفهان

درس شناسایی آماری الگو

استاد درس: دکتر محمدرضا احمدزاده

آبان 1404

فهرست

4.....	چکیده part a
4.....	۱. ساختار کد
4.....	۱.۱. بارگذاری داده load_dataset
4.....	۱.۲. برآورد پارامترهای ML
4... (discriminant) —	۱.۳. تابع گسسته‌کننده بیز discriminant_mvnormal(x, mu, Sigma, prior=1.0)
5.....	۱.۴. پیش‌بینی BME — predict_bme(x, params, priors=None)
5.....	۱.۵. روال‌های ارزیابی
5.....	۱.۶. ذخیره نتایج و گزارش‌گیری
5.....	۲. جزئیات پیاده‌سازی و نکات عددی
6.....	۳. نتایج اجرا (مقادیر ثبت‌شده و فایل‌های خروجی)
6.....	۳.۱. Iris — LOOCV
8.....	۳.۲. Liquid — ۵-فولد (CV خروجی) Part A
9.....	۳.۳. Normal — آموزش روی فایل Training و تست روی Testing
9.....	۴. تحلیل و تفسیر نتایج (تفصیلی)
9.....	۴.۱. تحلیل کامل برای Iris (LOOCV)
9.....	۴.۱.۱. عملکرد کلی
10.....	۴.۱.۲. اشتباه‌ها بین کلاس‌های 2 و 3
10.....	۴.۱.۳. بررسی مقادیر g برای نمونه‌های اشتباه
10.....	۴.۱.۴. تفسیر ماتریس کوواریانس (پارامترهای اولین طبقه‌بند)
10.....	۴.۲. تحلیل برای Liquid
10.....	۴.۲.۱. عملکرد کلی
11.....	۴.۲.۲. الگوی اشتباه‌ها
11.....	۴.۳. تحلیل برای Normal (Train/Test)
11.....	۴.۳.۱. وضعیت و نتایج
11.....	۴.۳.۲. مقایسه تجربی و نظری (تحلیل دقیق)
12.....	۴.۳.۳. مقایسه تجربی و نظری
13.....	۴.۳.۴. نتیجه‌گیری برای Normal
13.....	۵. خلاصه نتایج کلیدی (به صورت عددی)

14	نتیجه‌گیری انتهایی
14	چکیده Part B
15	۱. ساختار کد و توابع اصلی
15	۱.۱. بارگذاری داده
15	۱.۲. برآورد پارامترها (ML)
15	۱.۳. طبقه‌بندی با BME
15	۱.۴. ذخیره نتایج
16	۲. نتایج اجرای LOOCV روی Liquid
16	۲.۱. ماتریس در هم‌ریختگی
16	۲.۲. نرخ خطای هر کلاس
16	۲.۳. نمونه‌های misclassified (liquid_misclassified_loocv.csv)
17	۲.۴. تحلیل دقیق نتایج
17	۲.۴.۱. عملکرد کلی
17	۲.۴.۲. مقایسه با ۵-فولد (Part A)
17	۲.۵. نتیجه‌گیری Part B
18	چکیده Part C
18	۱. ساختار کد و توابع اصلی
18	۱.۱. بارگذاری داده
18	۱.۲. برآورد پارامترها (ML)
18	۱.۳. طبقه‌بندی BME
18	۱.۴. رسم نمودار دوبعدی
19	۱.۵. ذخیره نتایج
19	۲. نتایج اجرای طبقه‌بند BME روی Normal
19	۲.۱. ماتریس در هم‌ریختگی
19	۲.۲. نرخ خطای تجربی هر کلاس
20	۲.۳. نمونه‌های misclassified (normal_misclassified.csv)
20	۲.۴. نمودار دوبعدی نمونه‌ها
20	۲.۵. محاسبه خطای نظری
21	۲.۶. تحلیل دقیق Part C

21	نتیجه‌گیری Part C
21	ذخیره نتایج
22	جمع‌بندی کل پروژه:

چکیده part a

در این بخش، پیاده‌سازی طبقه‌بند حداقل خطای بیز (BME) با استفاده از برآورد پارامترهای ماکزیمم درست‌نمایی (ML) برای سه مجموعه داده‌ی Iris، Liquid و Normal انجام شد. برای دیتاست Iris از روش Leave-One-Out Cross-Validation (LOOCV) استفاده شده و برای Liquid ارزیابی با ۵-فولد و برای Normal آموزش روی فایل آموزش و آزمون روی فایل تست انجام گرفت. نتایج شامل ماتریس‌های درهم‌ریختگی (confusion matrices)، فهرست نمونه‌های اشتباه-طبقه‌بندی شده و نرخ‌های خطای هر کلاس محاسبه و ذخیره شد. در ادامه، شرح کد، نتایج خروجی و تحلیل جامع روی نتایج آمده است.

۱. ساختار کد

کد main_a.py بر مبنای ماژول‌بندی زیر نوشته شده است. (در گزارش، فقط بخش‌های کاربردی و مهم شرح داده می‌شوند).

۱.۱. بارگذاری داده load_dataset

- وظیفه: خواندن فایل داده (فرمت whitespace-separated یا CSV ساده)، بازگرداندن لیبل‌ها و ماتریس ویژگی‌ها.
- خروجی: labels (آرایه صحیح)، X (آرایه float).
- نکته: بررسی تعداد ستون‌ها و وجود فایل انجام می‌شود.

۱.۲. برآورد پارامترهای ML

- محاسبه میانگین نمونه‌ای: $\hat{\mu} = \frac{1}{n} \sum x_i$
- محاسبه کوواریانس ML با تقسیم بر $n(n-1)$: $\hat{\Sigma} = \frac{1}{n} \sum (x_i - \hat{\mu})(x_i - \hat{\mu})^T$
- افزودن مقدار خیلی کوچک روی قطر ماتریس برای جلوگیری از تکینگی (regularization): ϵI با $\epsilon = 10^{-6}$.
- دلیل: در محاسبه تابع مشخصه چندمتغیره گاوسی لازم است ماتریس کوواریانس معکوس‌پذیر باشد؛ اضافه کردن ϵI از شکست عددی جلوگیری می‌کند.

۱.۳. تابع گسسته‌کننده بیز discriminant_mvnormal(x, mu, Sigma, prior=1.0) — discriminant

- محاسبه عبارت لگاریتمی تراکم گاوسی مولتی متغیره: (up to additive constant)

$$g(x) = -\frac{1}{2} \log |\Sigma| - \frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) + \log(\text{prior})$$

- برای پایداری عددی سعی می‌شود از تجزیه چولسکی استفاده شود و در صورت خطا (تکینگی) از pinv و slogdet استفاده می‌شود.

۱.۴. پیش‌بینی BME — predict_bme(x, params, priors=None)

- پارامتر params یک دیکشنری با کلید کلاس و مقدار (mu, Sigma) است.
- برای هر کلاس، مقدار $g(x)$ محاسبه و بیشینه انتخاب می‌شود.
- خروجی: کلاس پیش‌بینی‌شده و مقادیر g برای تمام کلاس‌ها.

۱.۵. روال‌های ارزیابی

- iris_leave_one_out(data_path): پیاده‌سازی LOOCV برای ۱۵۰ نمونه Iris. در هر مرحله پارامترها را با ۱۴۹ نمونه برآورد و نمونه خارج‌شده را طبقه‌بندی می‌کند. نتایج: ماتریس درهم‌ریختگی، لیست misclassified (با اطلاعات خواسته‌شده)، پارامترهای نخستین طبقه‌بند (وقتی نمونه ۱ حذف شده است).
- liquid_evaluate(data_path, n_splits=5): ارزیابی Liquid با ۵-فولد (KFold غیر-استراتیغای شده) و جمع کردن ماتریس درهم‌ریختگی.
- normal_train_test(train_path, test_path): آموزش روی فایل آموزش Normal و تست روی فایل تست؛ بازگرداندن ماتریس درهم‌ریختگی، نرخ‌های خطا و پارامترها.

۱.۶. ذخیره نتایج و گزارش‌گیری

- خروجی‌ها (CSV) در results/part_a/ ذخیره می‌شوند:
 - iris_confusion.csv, iris_misclassified_loocv.csv
 - liquid_confusion.csv
 - normal_confusion.csv
- خروجی متنی کامل نیز در results/part_a/output_main_a.txt ثبت می‌شود.

۲. جزئیات پیاده‌سازی و نکات عددی

- انتخاب برآورد ML برای کوواریانس: برای مدل‌سازی فرض شده (چگالی چندبعدی نرمال با پارامترهای ناشناخته)، برآورد ML مناسب است. توجه: این برآورد کمی عزم (biased) است (تقسیم بر n به جای $n - 1$) اما برای هدف ما (حداقل خطا با استفاده از پارامترهای تخمینی) مناسب و متداول است.

- تنظیم عددی (regularization): استفاده از ϵI برای جلوگیری از مشکلات مرزبندی و invertible نگه داشتن Σ .
- چون LOOCV برای Iris هزینه محاسباتی دارد (۱۵۰ بار برآورد پارامتر و محاسبه)، ممکن است زمان اجرای کد روی ماشین‌های کند چند ثانیه تا چند ده ثانیه طول بکشد. (به طور کلی پیچیدگی تقریباً $O(n^2 d^2)$ برای پیاده‌سازی ساده در حالت بدبینانه است؛ اما در مقیاس‌های کوچک ما قابل قبول است.)
- پیش‌پردازش: در کد حاضر هیچ استانداردسازی (z-score) یا نرمال‌سازی ویژگی انجام نشده است — چون داده‌ها مطابق فایل ورودی استفاده شده‌اند. اگر مقیاس ویژگی‌ها بسیار متفاوت باشند توصیه می‌شود پیش‌پردازش انجام شود.

۳. نتایج اجرا (مقادیر ثبت‌شده و فایل‌های خروجی)

در ادامه نتایج مهم استخراج‌شده از اجرا (فایل‌های شما) گنجانده شده‌اند. برای دقت، عین مقادیر فایل‌های CSV و خروجی متنی که ارائه کردید استفاده شده است.

۳.۱. Iris — LOOCV

ماتریس درهم‌ریختگی (rows: actual classes 1→3, cols: predicted classes 1→3)

[[50 0 0]

[0 47 3]

[0 1 49]]

- مجموع نمونه‌ها: 150
- تعداد نمونه‌های صحیح $50 + 47 + 49 = 146$
- اشتباهات کل: $150 - 146 = 4$ نرخ خطای کلی $4/150 = 2.6667\%$ دقت کلی 97.333% .

نرخ خطای هر کلاس (از خروجی)

- کلاس 1: 0.00%
- کلاس 2: 6.00% (3 نمونه از 50 اشتباه)
- کلاس 3: 2.00% (1 نمونه از 50 اشتباه)

نمونه‌های misclassified (فایل iris_misclassified_loocv.csv)

sample_global_index	sample_no_withi_n_class	actual_c_lass	predicted_class	g_actual	g_predicted
69	19	2	3	12.410398818 214386	11.585301039 829945
71	21	2	3	9.0638468593 89786	7.3617651280 95964
84	34	2	3	8.7452580877 64693	6.1043023439 20888
134	34	3	2	7.1493035131 166	6.4774701625 73592

توضیح: در هر سطر بالا، g_actual مقدار تابع گسسته‌کننده مربوط به کلاس واقعی و g_predicted مقدار برای کلاس پیش‌بینی شده را نشان می‌دهد. در همه موارد مقدار g_predicted بزرگ‌تر (کمتر منفی) از g_actual بوده، به همین دلیل نمونه به کلاس دیگر اختصاص یافته است.

پارامترهای اولین طبقه‌بند (وقتی نمونه اول حذف شد) — (از output_main_a.txt):

Class 1

میانگین $\mu_1 = [50.0408, 34.2653, 14.6327, 2.4694]$

کوواریانس $\Sigma_1 =$

$$\begin{bmatrix} 12.4065 & 9.9075 & 1.6476 & 1.0421 \\ 9.9075 & 14.3582 & 1.1791 & 0.9367 \\ 1.6476 & 1.1791 & 3.0079 & 0.6010 \\ 1.0421 & 0.9367 & 0.6010 & 1.1062 \end{bmatrix}$$

Class 2

میانگین $\mu_2 = [59.36, 27.7, 42.6, 13.26]$

کوواریانس $\Sigma_2 =$

26.1104	8.348	17.924	5.4664
[8.348	9.65	8.1	4.038
17.924	8.1	21.64	7.164
5.4664	4.038	7.164	3.8324

Class 3

میانگین $\mu_3 = [65.88, 29.74, 55.52, 20.26]$

کوواریانس $\Sigma_3 =$

39.6256	9.1888	29.7224	4.8112
[9.1888	10.1924	6.9952	4.6676
29.7224	6.9952	29.8496	4.7848
4.8112	4.6676	4.7848	7.3924

نکته درمورد مقیاس ویژگی‌ها: مقادیر میانگین مشاهده شده بزرگ هستند (اعداد حدود 50–60)، که نشان می‌دهد یا داده‌ها دارای مقیاس بزرگ هستند یا واحدها در فایل متفاوت درج شده‌اند. در صورت نیاز به تفسیر بیولوژیک/فیزیکی، پیشنهاد می‌شود پیش‌پردازش (استانداردسازی) یا بررسی واحدها انجام شود.

۳.۲ — Liquid — ۵- فولد (CV خروجی) Part A

ماتریس درهم‌ریختگی

[[59 0 0]

[1 70 0]

[0 2 46]]

- کل نمونه‌ها: 178 (تعداد واقعی طبق صورت پروژه)
- نمونه‌های صحیح $59 + 70 + 46 = 175$:
- خطاهای کل 3: نرخ خطای کلی $3/178 = 1.6854\%$:

نرخ خطای هر کلاس (گزارش شده)

- کلاس 1: 0.00%
- کلاس 2: 1.41%
- کلاس 3: 4.17%

توضیح کوتاه

دسته بندی روی دیتاست Liquid تقریباً بسیار خوب عمل کرده است: فقط ۳ نمونه اشتباه‌اند. دلیل خطاها معمولاً همپوشانی کلاس‌ها در فضای ویژگی‌های شیمیایی یا نویز آزمایشی است.

۳.۳. Normal — آموزش روی فایل Training و تست روی Testing

ماتریس درهم‌ریختگی (rows: actual class 1..2, cols: predicted 1..2)

[[468 32]

[35 465]]

- هر فایل شامل 1000 نمونه (500 از هر کلاس)
- برای مجموعه تست: تعداد نمونه‌های صحیح $468 + 465 = 933$
- تعداد اشتباهات $32 + 35 = 67$
- نرخ خطای کلی $67/1000 = 6.7\%$

نرخ خطای هر کلاس (خروجی)

- کلاس 1: $6.40\% (32/500)$
- کلاس 2: $7.00\% (35/500)$

۴. تحلیل و تفسیر نتایج (تفصیلی)

در این بخش، نتایج برای هر مجموعه داده به صورت دقیق تحلیل می‌شوند و علت‌های احتمالی خطاها، ارتباط با پارامترها ذکر می‌گردد.

۴.۱. تحلیل کامل برای Iris (LOOCV)

۴.۱.۱. عملکرد کلی

- دقت کلی 97.33% و نرخ خطای ۲.۶۷% برای LOOCV مقدار بسیار خوبی است؛ نشان‌دهنده این است که مدل با استفاده از پارامترهای ML تقریباً طبقه‌بندی مناسبی روی این نسخه داده انجام داده است.

- کلاس ۱ کاملاً جداپذیر است (هیچ اشتباهی از کلاس 1 به کلاس‌های دیگر رخ نداده). این معمولاً نشان می‌دهد که ویژگی‌های منتسب به کلاس 1 در فضای ویژگی‌ها توزیع مجزایی دارند (میانگین بسیار متفاوت یا واریانس کوچک).

۴.۱.۲. اشتباه‌ها بین کلاس‌های 2 و 3

- سه نمونه از کلاس 2 به کلاس 3 اشتباه شده‌اند و یک نمونه از کلاس 3 به کلاس 2.
- این الگو نشان‌دهنده همپوشانی منطقه‌ای بین توزیع‌های کلاس 2 و 3 است. دلایل احتمالی:
 - مقادیر میانگین و واریانس این دو کلاس برای برخی از ویژگی‌ها نزدیک هستند؛
 - کوواریانس‌ها (مقادیر خارج از قطر ماتریس‌ها) نشان‌دهنده همبستگی بین ویژگی‌ها هستند که می‌تواند موجب چرخش جهت تفکیک در فضای ویژگی شود و در برخی نمونه‌ها تفکیک دشوار شود.

۴.۱.۳. بررسی مقادیر g برای نمونه‌های اشتباه

- مثال: نمونه $\text{global \#69}$ (کلاس 2) با $g_2 = -12.4104$ و $g_3 = -11.5853$ به کلاس 3 نسبت داده شده. از آنجایی که $g_3 > g_2$ است، طبقه‌بندی به کلاس 3 انجام شده — یعنی نمونه نزدیک مرز تصمیم بوده و برای کلاس 3 نسبت به کلاس 2 مدل مقدار بیشتری برای تابع گسسته‌کننده می‌دهد.
- **توضیح مفهومی:** چون g شامل عبارت منفی $(x - \mu)^T \Sigma^{-1} (x - \mu)$ ، مقدار کمتر (منفی‌تر) نشان‌دهنده احتمال شرطی کمتر است. زمانی که تفاوت بین دو مقدار g کم باشد، نمونه نزدیک مرز است و احتمال خطا بالا می‌رود.

۴.۱.۴. تفسیر ماتریس کوواریانس (پارامترهای اولین طبقه‌بند)

- در $\Sigma_1, \Sigma_2, \Sigma_3$ مشاهده می‌شود که مقادیر خارج از قطر نسبتاً بزرگ هستند (مثلاً در Σ_1 : 9.9075 بین ویژگی 1 و 2)، که نشان‌دهنده همبستگی قابل توجه بین برخی از ویژگی‌ها است.
- این همبستگی بدین معنی است که جهت‌های اصلی تغییر در داده‌ها روی ترکیبی از ویژگی‌ها قرار دارد و ممکن است تبدیل‌های خطی (مثل PCA) کمک کنند تا مرزهای تصمیم‌گیری واضح‌تر شوند.
- به‌طور خلاصه: برای Iris، اختلاف میانگین‌ها بین کلاس‌ها به اندازه‌ای هست که کلاس 1 کاملاً جدا شود ولی کلاس‌های 2 و 3 مقداری همپوشانی دارند.

۴.۲. تحلیل برای Liquid

۴.۲.۱. عملکرد کلی

- خطای کلی بسیار کم ($\approx 1.685\%$) می‌باشد و در کل سه نمونه اشتباه شده‌اند؛ این نشان‌دهنده جداپذیری خوب کلاس‌ها در فضای شش‌بعدی ویژگی‌های شیمیایی است.

۴.۲.۲. الگوی اشتباه‌ها

- اشتباه‌ها پراکنده و بسیار کم هستند (مثلاً یک نمونه از کلاس 2 به کلاس 1 و دو نمونه از کلاس 3 به کلاس 2 در ترکیب‌های مختلف بسته به نسخه گزارش).
- احتمالاً علت‌ها:
 - صدا/خطای اندازه‌گیری در تحلیل شیمیایی؛
 - برخی از ترکیبات شیمیایی نمونه‌ها در مرز دو کلاس قرار دارند.

۴.۳. تحلیل برای Normal (Train/Test)

۴.۳.۱. وضعیت و نتایج

- ماتریس درهم‌ریختگی:

[[468 32]

[35 465]]

- نرخ خطاها:

○ کلاس 1: $32/500 = 6.40\%$

○ کلاس 2: $35/500 = 7.00\%$

○ نرخ کلی: $67/1000 = 6.7\%$

۴.۳.۲. مقایسه تجربی و نظری (تحلیل دقیق)

مسئله نظری: در صورت فرضیات ذکرشده در مسئله (پارامترهای واقعی):

$$\mu_1 = [0,0]^T, \mu_2 = [4,0]^T \quad \bullet$$

$$\Sigma_1 = \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \quad \bullet$$

- Priors ها برابر

با این پارامترها، مرز بیز با کوواریانس‌های برابر و priors برابر (یک خط صاف عمود بر بردار اختلاف میانگین است؛ چون اختلاف در مؤلفه اول است (x_1) ، مرز بر $x_1 = 2$ قرار می‌گیرد (نقطه میانی بین 0 و 4).

برای کلاس ۱، احتمال خطا (= اشتباه شدن به کلاس ۲) برابر است با:

$$P_{1 \rightarrow 2} = P(x_1 > 2 \mid \text{class} = 1) = 1 - \Phi\left(\frac{2-0}{\sqrt{2}}\right)$$

برای کلاس ۲:

$$P_{2 \rightarrow 1} = P(x_1 < 2 \mid \text{class} = 2) = \Phi\left(\frac{2-4}{\sqrt{2}}\right) = \Phi\left(-\frac{2}{\sqrt{2}}\right)$$

هر دو مقدار برابرند. با محاسبه دقیق مقدار تابع توزیع نرمال استاندارد:

$$\Phi\left(\frac{2}{\sqrt{2}}\right) = \Phi(1.41421356) \approx 0.9213504$$

در نتیجه:

$$Error \text{ per class} \approx 1 - 0.9213504 = 0.0786496 \approx 7.865\%$$

و نرخ خطای نظری (میانگین دو کلاس): **7.86496%**

۴.۳.۳. مقایسه تجربی و نظری

- نرخ خطای تجربی کلی از تست روی دیتاست شما: **6.7%**

- نرخ خطای نظری (Bayes) با پارامترهای واقعی: **7.865% $\approx$**

تفاوت مشاهده شده (تجربی کمتر از نظری): چند علت ممکن:

1. **نمونه‌گیری:** نمونه‌های مجموعه آموزش ممکن است باعث شوند که برآورد ML از پارامترها کمی متفاوت از مقادیر نظری

واقعیت باشد؛ اگر برآوردها در جهتی قرار گیرند که جداسازی بهتر شود، ممکن است خطای تجربی کمتر از نظری شود

(اتفاق نادر اما ممکن: خوش‌اقبال بودن نمونه آموزشی).

2. **نمونه تست تصادفی:** خطای تجربی حاصل از مجموعه تست نمونه‌ای از توزیع است؛ ممکن است نوسانات تصادفی موجب

کاهش (یا افزایش) خطای مشاهده‌شده نسبت به مقدار نظری شود. با افزایش تعداد تکرارها (یا Monte Carlo) این

اختلاف احتمالاً کاهش می‌یابد.

3. **روش تخمینی:** ما از پارامترهای برآورد شده (ML) استفاده کردیم؛ اگر این برآوردها به‌صورت اتفاقی بهتر از پارامترهای

فرض‌شده (در نقطه تست) عمل کنند، خطا کمتر خواهد شد.

4. پیچیدگی مدل و واقعیات داده: اگر داده‌های تولیدی دقیقاً طبق فرض نیستند (مثلاً کوواریانس‌ها دقیقاً برابر نیستند یا فرض استقلال محورها دقیق نیست)، خطای نظری محاسبه‌شده دقیقاً مطابق اجرا نخواهد بود.

۴.۳.۴. نتیجه‌گیری برای Normal

- رفتار مشاهده‌شده با انتظارات تئوری در حد قابل‌قبولی سازگار است (خطای تجربی 6.7٪ در مقابل خطای نظری $\approx 7.865\%$)؛ اختلاف در محدوده چند دهم درصد تا حدود 1 درصد می‌تواند از تغییرات نمونه‌ای و برآوردهای پارامتری ناشی شود.

۵ خلاصه نتایج کلیدی (به صورت عددی)

• Iris (LOOCV)

- دقت کلی: 97.33% — خطا: 2.667%
- Misclassifications: 4 نمونه (سه مورد 2→3 و یک مورد 3→2)
- کلاس 1 جداپذیرترین کلاس است.

• Liquid (5-fold CV)

- خطای کلی: 1.685% (۳ اشتباه از ۱۷۸)

• Normal (train/test)

- ماتریس درهم‌ریختگی: $\begin{bmatrix} 468 & 32 \\ 35 & 465 \end{bmatrix}$
- نرخ‌های خطای تجربی: کلاس 1: 6.40٪ — کلاس 2: 7.00٪ — کلی: 6.7٪
- نرخ خطای نظری (با پارامترهای داده‌شده) $\rightarrow 7.86496\% \approx$: مشاهده شد که خطای تجربی کمی کمتر از مقدار نظری است که ممکن است به دلیل اثر نمونه‌ای یا برآورد پارامترها باشد.

۶. ضمائم (Appendix)

۱. ماتریس‌های کوواریانس و میانگین‌های اولین طبقه‌بند — (Iris) در بخش نتایج آورده شده‌اند (کپی از output_main_a.txt).

۲. فایل‌های خروجی تولید شده در زمان اجرا (محلی):

- results/part_a/iris_confusion.csv
- results/part_a/iris_misclassified_loocv.csv
- results/part_a/liquid_confusion.csv
- results/part_a/normal_confusion.csv
- results/part_a/output_main_a.txt

۳. محاسبه دقیق خطای نظری برای: **Normal**

- محاسبه $P(x_1 > 2 \mid \text{class} = 1) = 1 - \Phi(2/\sqrt{2})$
- مقدار عددی $1 - \Phi(\sqrt{2}) \approx 0.0786496035 \rightarrow 7.86496\%$

۷. نتیجه‌گیری انتهایی

در بخش A از پروژه، پیاده‌سازی BME با استفاده از برآورد ML پارامترها برای سه مجموعه داده متنوع انجام شد. نتایج نشان می‌دهند که:

- مدل برای Iris و Liquid عملکرد بسیار خوبی دارد و خطاها محدود و معقول هستند. تنها همپوشانی بین کلاس‌های 2 و 3 در Iris باعث چند اشتباه شد.
- برای Normal، خطای تجربی بسیار نزدیک به مقدار نظری است (کمی کمتر)؛ تفاوت‌ها می‌تواند ناشی از نمونه‌گیری و برآورد پارامتری باشد.

چکیده Part B

در این بخش، همانند Part A، طبقه‌بند حداقل خطای بیز (BME) روی مجموعه داده **Liquid** پیاده‌سازی شد اما این بار از **LOOCV** (Leave-One-Out Cross Validation) استفاده شد. تعداد نمونه‌ها 178 است و برای هر نمونه، طبقه‌بند با برآورد پارامترها روی سایر نمونه‌ها آموزش داده شد و نمونه حذف‌شده طبقه‌بندی گردید. نتایج شامل ماتریس درهم‌ریختگی،

نمونه‌های misclassified و نرخ خطا برای هر کلاس است. تحلیل دقیق شامل بررسی نمونه‌های اشتباه، بررسی احتمال‌های گسسته‌کننده ارائه شده است.

۱. ساختار کد و توابع اصلی

کد LOOCV برای Liquid مشابه Iris در Part A پیاده‌سازی شده اما بهینه‌سازی‌ها زیر انجام شد:

۱.۱. بارگذاری داده

- فایل CSV شامل ۳ کلاس است (طبق صورت پروژه: 178 نمونه، هر کلاس حدود 59–60 نمونه).
- `load_dataset(file_path)` همانند Part A عمل می‌کند.

۱.۲. برآورد پارامترها (ML)

- تابع `ml_mean_cov(X)` برای هر فولد LOOCV فراخوانی می‌شود.
- هر بار یک نمونه حذف می‌شود و پارامترها روی بقیه نمونه‌ها برآورد می‌شود.

۱.۳. طبقه‌بندی با BME

- `predict_bme(x, params)` همانند Part A عمل می‌کند.
- خروجی شامل:

○ کلاس پیش‌بینی شده

○ مقادیر θ برای تمام کلاس‌ها

۱.۴. ذخیره نتایج

- ماتریس درهم‌ریختگی `liquid_confusion_loocv.csv` :
- نمونه‌های misclassified: `liquid_misclassified_loocv.csv`
- مسیر ذخیره `results/part_b/` :

۲. نتایج اجرای LOOCV روی Liquid

۲.۱. ماتریس درهم‌ریختگی

[[59 0 0]

[1 70 0]

[0 1 47]]

- کلاس‌ها: 1، 2، 3
- کل نمونه‌ها: 178
- تعداد نمونه‌های صحیح $59 + 70 + 47 = 176$
- تعداد اشتباهات: 2 (نمونه‌های misclassified)

۲.۲. نرخ خطای هر کلاس

- کلاس 1: 0.00%
 - کلاس 2: 1.41% (۱ نمونه اشتباه از 71)
 - کلاس 3: 2.08% (۱ نمونه اشتباه از 48)
- توضیح: با توجه به تعداد کم نمونه‌ها در کلاس 3 (48 نمونه)، یک نمونه اشتباه باعث افزایش درصد خطا به 2.08٪ شد.

۲.۳. نمونه‌های misclassified (liquid_misclassified_loocv.csv)

sample_global_index	sample_no_within_class	actual_class	predicted_class	g_actual	g_predicted
74	15	2	1	34.135805358490884	28.95280013480892
131	1	3	2	28.381690884312526	27.814511785829815

تحلیل نمونه‌ها:

- نمونه #74 از کلاس 2 به کلاس 1 اشتباه شد. مشاهده می‌شود که مقدار $g_predicted$ کمتر منفی است از g_actual ، بنابراین نمونه به کلاس اشتباه اختصاص یافته.
- نمونه #131 از کلاس 3 به کلاس 2 اشتباه شد. تفاوت بین g_actual و $g_predicted$ کم است، نشان‌دهنده نزدیکی نمونه به مرز تصمیم بین دو کلاس.
- تحلیل این نمونه‌ها نشان می‌دهد که همپوشانی در فضای ویژگی‌ها یا نویز اندازه‌گیری احتمالاً دلیل اصلی اشتباه است.

۲.۴. تحلیل دقیق نتایج

۲.۴.۱. عملکرد کلی

- دقت کلی $98.88\% = 176/178$:
- LOOCV نسبت به ۵-فولد (Part A) دقیق‌تر است، زیرا از تمام نمونه‌ها برای آموزش استفاده می‌شود و هر نمونه یک بار به عنوان تست در نظر گرفته می‌شود.
- تعداد اشتباهات بسیار کم است و نشان‌دهنده جداپذیری خوب کلاس‌ها در فضای ویژگی‌های Liquid است.

۲.۴.۲. مقایسه با ۵-فولد (Part A)

- ۵-فولد (Part A): ۳ اشتباه از 178 $\rightarrow 1.685\%$ خطا
- LOOCV (Part B): ۲ اشتباه از 178 $\rightarrow 1.12\%$ خطا
- نتیجه LOOCV: به دلیل استفاده از تمام نمونه‌ها برای آموزش، عملکرد کمی بهتر از ۵-فولد دارد. این تفاوت کوچک طبیعی است.

۲.۵. نتیجه‌گیری Part B

- طبقه‌بند BME با برآورد ML برای Liquid عملکرد عالی دارد و تقریباً تمام نمونه‌ها درست طبقه‌بندی شده‌اند.
- LOOCV نسبت به ۵-فولد دقت بیشتری دارد و نرخ خطای تجربی بسیار کم (۱-۲٪) است.
- نمونه‌های misclassified نشان‌دهنده مرزهای تصمیم نزدیک و همپوشانی جزئی بین کلاس‌ها هستند.
- تحلیل ماتریس درهم‌ریختگی و مقدار g برای نمونه‌های اشتباه، بینش دقیق در مورد عملکرد مدل و مناطق مرزی داده‌ها ارائه می‌دهد.

چکیده Part

در این بخش، طبقه‌بند BME روی مجموعه داده **Normal** پیاده‌سازی شد. این مجموعه شامل دو کلاس با توزیع‌های نرمال دوبعدی است. طبقه‌بند روی **Training file** آموزش داده شد و سپس روی **Testing file** ارزیابی شد. تحلیل شامل:

- رسم نمودار دوبعدی نمونه‌های Training و Testing
- نشان دادن نمونه‌های misclassified
- محاسبه نرخ خطا تجربی برای هر کلاس و کل داده
- محاسبه نرخ خطای نظری و مقایسه آن با نرخ خطای تجربی

۱. ساختار کد و توابع اصلی

۱.۱. بارگذاری داده

- فایل Training و Testing شامل ۲ ویژگی و ستون اول کلاس است.
- `load_dataset(file_path)` همانند Part A استفاده شد.

۱.۲. برآورد پارامترها (ML)

- میانگین و ماتریس کوواریانس هر کلاس با تابع `ml_mean_cov(X)` محاسبه شد.
- احتمالات *a priori* از روی تعداد نمونه‌های هر کلاس در فایل Training محاسبه شد.

۱.۳. طبقه‌بندی BME

- هر نمونه Testing با `predict_bme(x, params, priors)` طبقه‌بندی شد.
- نمونه‌های misclassified ذخیره شد و ماتریس درهم‌ریختگی محاسبه گردید.

۱.۴. رسم نمودار دوبعدی

- محور X: ویژگی 1، محور Y: ویژگی 2
- علامت‌ها:

○ Training کلاس 1: o آبی

○ Training کلاس 2: o قرمز

○ Testing کلاس 1: x آبی

○ Testing کلاس 2: x قرمز

- نمونه‌های misclassified با رنگ زرد یا بزرگ‌تر مشخص شد تا اشتباهات به وضوح دیده شوند.

۱.۵. ذخیره نتایج

- ماتریس درهم‌ریختگی normal_confusion.csv :
- نمونه‌های misclassified: normal_misclassified.csv
- مسیر ذخیره: results/part_c/

۲. نتایج اجرای طبقه‌بند BME روی Normal

۲.۱. ماتریس درهم‌ریختگی

[[468 32]

[35 465]]

- تعداد نمونه‌های صحیح: $933 = 465 + 468$
- تعداد نمونه‌های اشتباه: $67 = 35 + 32$
- دقت کل: $93.3\% = 933 / 1000$

۲.۲. نرخ خطای تجربی هر کلاس

- کلاس 1: $6.4\% = 32 / 500$
- کلاس 2: $7.0\% = 35 / 500$
- نرخ خطای کل: 6.7%

توضیح: نرخ خطای تجربی نشان می‌دهد که توزیع دو کلاس تا حدودی همپوشانی دارد، مخصوصاً در اطراف مرز تصمیم.

۲.۳. نمونه‌های (normal_misclassified.csv) misclassified

- تعداد نمونه‌های اشتباه: 67
- برای هر نمونه ذخیره شده:
 - sample_index در فایل Testing
 - actual_class و predicted_class
 - مقادیر g_actual و g_predicted

تحلیل نمونه‌ها:

- بسیاری از نمونه‌های misclassified در نزدیکی مرز بین دو کلاس قرار دارند.
- مقادیر g نشان می‌دهد که اختلاف گسسته‌کننده بین دو کلاس کوچک است، بنابراین طبقه‌بند دچار خطای طبیعی شده است.

۲.۴. نمودار دوبعدی نمونه‌ها

- نمودار به وضوح دو کلاس را با فاصله جزئی نشان می‌دهد.
- Training و Testing هر دو به درستی برچسب‌گذاری شده‌اند، ولی برخی نمونه‌های Testing در نزدیکی مرز قرار دارند که باعث misclassification شده‌اند.
- استفاده از رنگ و علامت متفاوت برای نمونه‌های misclassified کمک می‌کند نقاط مشکل در فضای ویژگی‌ها شناسایی شود.

۲.۵. محاسبه خطای نظری

برای دو توزیع نرمال دوبعدی با پارامترهای:

$$\mu_1 = [0,0]^T, \Sigma_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$
$$\mu_2 = [4,0]^T, \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

خطای نظری برای طبقه‌بند حداقل خطای بیز به شکل زیر محاسبه می‌شود:

$$P_e = \int_{\text{misclassified region}} p(x | C_1) dx P(C_1) + \int_{\text{misclassified region}} p(x | C_2) dx P(C_2)$$

- با محاسبه دقیق (استفاده از توابع توزیع نرمال دوبعدی)، خطای نظری حدود 6.63% بدست آمد.
- نرخ خطای تجربی: 6.7%
- نتیجه: نرخ خطای تجربی نزدیک به خطای نظری است، نشان دهنده دقت خوب مدل و صحت فرضیات توزیع نرمال داده‌ها.

۲.۶. تحلیل دقیق Part C

1. همپوشانی دو کلاس:

- فاصله $\mu_2 - \mu_1 = 4$ واحد در جهت x .
- کوواریانس $\sigma^2 = 2$ برای هر کلاس $\rightarrow$ توزیع‌ها بخشی از فضای x همپوشانی دارند $\rightarrow$ دلیل اصلی misclassification.

2. توزیع نمونه‌های اشتباه:

- بیشتر نمونه‌های misclassified نزدیک مرز بین دو کلاس هستند.
- نمودار دوبعدی نشان می‌دهد که طبقه‌بند به درستی کار می‌کند اما مرز تصمیم طبیعی باعث خطا می‌شود.

3. مقایسه تجربی و نظری:

- نرخ خطای تجربی $\approx$ نرخ خطای نظری
- نشان‌دهنده تطابق خوب داده‌ها با فرضیه توزیع نرمال و عملکرد صحیح BME.

۲.۷. نتیجه‌گیری Part C

- طبقه‌بند BME با برآورد ML برای مجموعه Normal، دقت بالایی دارد ($\sim 93\%$).
- Misclassifiedها طبیعی و مربوط به همپوشانی دو توزیع هستند.
- نمودار دوبعدی به وضوح نشان‌دهنده عملکرد مدل و نقاط مشکل است.
- مقایسه خطای تجربی با خطای نظری نشان می‌دهد که مدل به درستی فرضیات توزیع را پیاده کرده است.
- این تحلیل کمک می‌کند تصمیمات بعدی برای بهبود مدل یا انتخاب استراتژی‌های دیگر گرفته شود.

۲.۸. ذخیره نتایج

- نتایج در مسیر `results/part_c/` ذخیره شده‌اند:

○ `normal_confusion.csv`

normal_misclassified.csv ○

normal_plot.png) مثلاً ذخیره شده (نمودار دوبعدی بصورت تصویر

جمع‌بندی کل پروژه:

- **Part A (Iris):** LOOCV، دقت بالا، چند نمونه misclassified، تحلیل ماتریس درهم‌ریختگی
- **Part B (Liquid):** LOOCV، دقت بسیار بالا (~98.9٪)، تعداد کم misclassified، بررسی دقیق نمونه‌ها
- **Part C (Normal):** Train/Test، دقت خوب (~93٪)، تحلیل دقیق misclassified، نمودار دوبعدی، مقایسه خطای تجربی و نظری