



گزارش تکلیف کامپیوتری شماره یک

تولید و تحلیل مجموعه داده شامل سه کلاس نرمال دویعدی



علیرضا مهدی‌زاده 40416814

دانشجوی کارشناسی ارشد هوش مصنوعی دانشگاه صنعتی اصفهان

درس شناسایی آماری الگو

استاد درس: دکتر محمدرضا احمدزاده

آبان 1404

1. هدف آزمایش

هدف این آزمایش تولید یک مجموعه داده مصنوعی با سه کلاس هم‌احتمال است که هر کلاس توسط یک توزیع نرمال دوبعدی مدل می‌شود. هر کلاس دارای میانگین و ماتریس کوواریانس مشخصی است و نمونه‌های تولید شده برای تحلیل و طبقه‌بندی (همچون تصمیم‌گیرنده بیزی) مورد استفاده قرار می‌گیرند. مشخصات کلاس‌ها به‌صورت زیر تعریف شده‌اند:

$$m_1 = [1, 1]^T, m_2 = [10, 5]^T, m_3 = [11, 1]^T$$
$$S_1 = S_2 = S_3 = \begin{bmatrix} 7 & 4 \\ 4 & 5 \end{bmatrix}$$

تعداد کل نمونه‌ها: $N = 1000$
تعداد کلاس‌ها: $K = 3$

2. توضیح و تشریح کدها

کد در فایل `main.py` پیاده‌سازی شده است.

بخش 1 – ایجاد پوشه نتایج

```
results_dir = Path("results")
results_dir.mkdir(exist_ok=True)
```

در ابتدای برنامه پوشه‌ای به نام `results` ساخته می‌شود تا داده‌ها و خروجی‌ها در آن ذخیره شوند.

بخش 2 – تعریف پارامترهای کلاس‌ها

```
means = np.array([
    [1, 1],
    [10, 5],
    [11, 1]
])

cov = np.array([
    [7, 4],
    [4, 5]
])
```

در این بخش بردار میانگین‌ها و ماتریس کوواریانس مشترک برای سه کلاس تعریف می‌شوند.

بخش 3 – تولید داده‌ها

```

for i in range(K):
    start = i * N_per_class
    end = (i + 1) * N_per_class
    X[start:end, :] = np.random.multivariate_normal(means[i], cov,
N_per_class)
    labels[start:end] = i

```

با استفاده از تابع `np.random.multivariate_normal` از هر کلاس به تعداد مساوی (تقریباً 333 نمونه) داده تولید می‌شود. همچنین آرایه‌ی `labels` شامل برچسب کلاس هر نمونه است (0، 1 یا 2).

بخش 4 – ذخیره داده‌ها

```
np.savez(results_dir / "X4_dataset.npz", X=X, labels=labels)
```

کل داده‌ها و برچسب‌ها در یک فایل فشرده‌ی NumPy ذخیره می‌شوند تا بتوان در آزمایش‌های بعدی از آن استفاده کرد.

بخش 5 – ترسیم داده‌ها

```

plt.scatter(X[labels == i, 0], X[labels == i, 1], c=colors[i], s=20,
label=f'Class {i+1}')

```

داده‌ها بر اساس کلاس رنگ‌آمیزی شده و در یک نمودار دوبعدی نمایش داده می‌شوند. فایل خروجی در مسیر `results/X4_scatter.png` ذخیره می‌شود.

بخش 6 – ناحیه‌های تصمیم (Decision Regions)

```

pdfs = [multivariate_normal(mean=means[i], cov=cov).pdf(pos) for i in
range(K)]
decision_map = np.argmax(pdfs, axis=0)

```

در این بخش تابع چگالی احتمال هر کلاس روی شبکه‌ای از نقاط دوبعدی محاسبه شده و با استفاده از قانون بیز، ناحیه تصمیم برای هر کلاس تعیین می‌شود. خروجی این قسمت تصویری از مرزهای تصمیم‌بیزی است که در فایل `results/X4_decision_regions.png` ذخیره می‌گردد.

3. نتایج اجرا و تحلیل

الف) توزیع داده‌ها

خروجی شکل `X4_scatter.png` سه ابر داده را در صفحه‌ی دوبعدی نشان می‌دهد:

- **کلاس 1** در نزدیکی مبدأ قرار دارد (میانگین $[1,1]$)
- **کلاس 2** در ناحیه‌ی بالاتر (میانگین $[10,5]$)
- **کلاس 3** در سمت راست پایین‌تر (میانگین $[11,1]$)

با توجه به ماتریس کوواریانس مشترک (که درایه‌های خارج از قطر آن برابر 4 هستند) داده‌ها دارای همبستگی مثبت میان x_1 و x_2 هستند، بنابراین ابر داده‌ها به صورت بیضوی با زاویه نسبت به محورهای مختصات ظاهر می‌شوند.

(ب) نواحی تصمیم بیزی

خروجی شکل `x4_decision_regions.png` مرزهای تصمیم بیزی را نشان می‌دهد. مرزها به گونه‌ای ترسیم شده‌اند که احتمال اشتباه طبقه‌بندی در حالت توازن کلاس‌ها حداقل گردد.

مشاهده می‌شود:

- بین کلاس 1 و کلاس 2 مرز تقریباً قطری و در فاصله‌ی حدودی بین $x_1 = 5$ تا 7 قرار دارد.
- کلاس 2 و 3 به دلیل نزدیکی میانگین‌ها در محور x_1 و x_2 نواحی همپوشانی جزئی دارند.
- از آنجا که کوواریانس‌ها برابرند، مرزهای تصمیم تقریباً خطی هستند.

4. تحلیل نهایی

- داده‌های تولید شده رفتار سه کلاس گوسی را به‌خوبی نشان می‌دهند.
- همپوشانی جزئی بین کلاس‌ها طبیعی است و سبب خطای جزئی در طبقه‌بندی بیزی می‌شود.
- چون احتمال هر کلاس برابر است، تصمیم‌گیرنده بیزی تنها بر اساس مقدار تابع چگالی (likelihood) تصمیم می‌گیرد.
- شکل مرزها و توزیع داده‌ها برای تمرین‌های بعدی (محاسبه‌ی خطای بیزی و مقایسه‌ی روش‌های طبقه‌بندی دیگر) پایه‌ی مناسبی فراهم می‌کند.

5. فایل‌های خروجی ذخیره‌شده

در پوشه `results/` فایل‌های زیر ایجاد شدند:

نام فایل	توضیح
<code>x4_dataset.npz</code>	داده‌ها و برچسب‌های کلاس
<code>x4_scatter.png</code>	نمودار پراکندگی داده‌ها
<code>x4_decision_regions.png</code>	نواحی تصمیم بیزی

نتیجه نهایی:

با اجرای موفق این آزمایش، داده‌های مصنوعی سه‌کلاسه تولید، ذخیره و تحلیل شدند. نتایج به‌خوبی نشان می‌دهد که مدل بیزی با فرض توزیع‌های گاوسی توانایی تفکیک مناسب کلاس‌ها را دارد و با افزایش فاصله میانگین‌ها یا کاهش کوواریانس، دقت طبقه‌بندی بهبود خواهد یافت.